

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(УНИВЕРСИТЕТ ИТМО)

Факультет «Систем управления и робототехники»

**ОТЧЕТ
О ЛАБОРАТОРНОЙ РАБОТЕ №6**

По дисциплине «Практическая линейная алгебра»
на тему: «SINGULAR VALUE DECOMPOSITION»

Студенты:
Бурханова К.А. группа 3
Колун Д.В. группа 3
Полетаев В.А. группа 3
Шишкина М.Н. группа 3

Проверил:
Догадин Егор Витальевич, ассистент

Содержание

1	ВВЕДЕНИЕ	2
2	ХОД РАБОТЫ	2
2.1	Часть 1. Сжатие изображений.....	2
2.1.1	Подготовка изображения.....	2
2.1.2	Анализ сингулярных чисел.....	2
2.1.3	Эксперименты с различными значениями k	3
2.1.4	Процесс сжатия изображения.....	4
2.1.5	Расчет степени сжатия.....	5
2.1.6	Промежуточные выводы по сжатию.....	5
2.2	Часть 2. Latent Semantic Analysis.....	5
2.2.1	Предобработка текстов.....	5
2.2.2	Исходные данные.....	6
2.2.3	Анализ сингулярных чисел.....	6
2.2.4	Интерпретация компонентов SVD-разложения.....	6
2.2.5	Визуализация кластеризации.....	7
2.2.6	Анализ тем по словам.....	7
2.2.7	Облака слов.....	8
2.2.8	Промежуточные выводы по LSA.....	8
3	ВЫВОДЫ	8
3.1	По сжатию изображений.....	8
3.2	По Latent Semantic Analysis.....	9

1 ВВЕДЕНИЕ

В данной лабораторной работе исследуется применение сингулярного разложения (SVD) для решения двух практических задач: сжатия изображений и анализа текстовых данных. SVD является мощным инструментом линейной алгебры, позволяющим представить матрицу в виде произведения трех матриц: $A = U \Sigma V^T$, где U и V – ортогональные матрицы, а Σ – диагональная матрица сингулярных чисел.

2 ХОД РАБОТЫ

2.1 Часть 1. Сжатие изображений

2.1.1 Подготовка изображения

Для демонстрации метода сжатия было выбрано изображение в оттенках серого. Изображение было представлено в виде матрицы значений интенсивности пикселей.



Рис. 1: Исходное изображение

2.1.2 Анализ сингулярных чисел

После выполнения SVD-разложения был построен график сингулярных чисел, показывающий их распределение и скорость убывания.




Рис. 2: Спектр сингулярных чисел

2.1.3 Эксперименты с различными значениями k

Были проведены эксперименты с различными значениями параметра k (количество оставляемых сингулярных чисел):




Рис. 3: Сжатие при $k=1$ (слева) и $k=5$ (справа)

Сжатие ($k=20$)



Сжатие ($k=50$)





Рис. 4: Сжатие при $k=20$ (слева) и $k=50$ (справа)

Сжатие ($k=100$)



Сжатие ($k=200$)




Рис. 5: Сжатие при $k=100$ (слева) и $k=200$ (справа)

2.1.4 Процесс сжатия изображения

Для сжатия изображения мы использовали Python с библиотеками NumPy и PIL. Основные шаги алгоритма:

1. Загрузка изображения и преобразование в оттенки серого:

```
from PIL import Image
import numpy as np

# Загрузка и конвертация в оттенки серого
img = Image.open('cat.jpg').convert('L') #
Преобразование в массив numpy
image = np.array(img)
```

2. Выполнение SVD разложения:

```
# Разложение матрицы изображения
U, s, Vt = np.linalg.svd(image, full_matrices=False)
```

3. Сжатие путем отбора k компонент:

```
# Сжатие с использованием k компонент
compressed = U[:, :k] @ np.diag(s[:k]) @ Vt[:k, :]
```

2.1.5 Расчет степени сжатия

Для каждого значения k мы рассчитывали эффективный размер сжатого изображения следующим образом:

- Исходный размер: $m \times n$ элементов
- Размер сжатого представления: $k(m + n + 1)$ элементов, где:
 - $k \times m$ элементов из матрицы U
 - $k \times n$ элементов из матрицы Vt
 - k элементов из вектора сингулярных чисел
- Степень сжатия = $\frac{m \times n}{k(m+n+1)}$

Результаты сжатия для разных значений k :

- $k = 1$: степень сжатия 319.8:1
- $k = 5$: степень сжатия 64:1
- $k = 20$: степень сжатия 16:1
- $k = 50$: степень сжатия 6.4:1
- $k = 100$: степень сжатия 3.2:1
- $k = 200$: степень сжатия 1.6:1

2.1.6 Промежуточные выводы по сжатию

В результате экспериментов с SVD-сжатием мы обнаружили:

- При $k = 200$ достигается оптимальный баланс между качеством и степенью сжатия
- Основные черты изображения сохраняются даже при значительном сжатии ($k = 50$)
- Быстрое убывание сингулярных чисел позволяет эффективно определить оптимальное значение k

2.2 Часть 2. Latent Semantic Analysis

2.2.1 Предобработка текстов

Для анализа были выполнены следующие шаги предобработки текстов:

1. Удаление знаков препинания и приведение к нижнему регистру
2. Лемматизация с помощью библиотеки `pymystem3` (основана на морфологическом анализаторе Яндекса `Mystem`)
3. Удаление стоп-слов с помощью `NLTK`
4. Создание терм-документной матрицы с помощью `CountVectorizer`

Лемматизация выполняется с помощью библиотеки `pymystem3`, которая основана на морфологическом анализаторе Яндекса `Mystem`. Это позволяет корректно обрабатывать русскоязычные тексты, приводя слова к их начальной форме (лемме). Например:

- книги, книгой, книгам → "книга"
- читал, читаю, читающий → "читать"

Такая обработка позволяет улучшить качество анализа текста, так как различные формы одного и того же слова рассматриваются как одно слово, что делает анализ более точным и информативным.

Стоп-слова (предлоги, союзы, местоимения и другие часто встречающиеся слова, не несущие смысловой нагрузки) удаляются с использованием предопределенного списка русских стоп-слов из NLTK.

2.2.2 Исходные данные

Для анализа был использован текст из файла data20.txt(приводится фрагмент):

"Подсчёт калорий помогает контролировать массу тела и достигать фитнес-целей.",
 "Процесс укладки асфальта начинается с подготовки дорожного основания." и т.д

2.2.3 Анализ сингулярных чисел

После построения терм-документной матрицы было выполнено её SVD-разложение и проанализирован спектр сингулярных чисел.




Рис. 6: Спектр сингулярных чисел терм-документной матрицы

2.2.4 Интерпретация компонентов SVD-разложения

В контексте анализа текстов компоненты SVD-разложения имеют следующий смысл:

- Столбцы матрицы U (левые сингулярные векторы) представляют собой веса термов для каждой выявленной темы. Каждый столбец соответствует одной теме, а значения в нём показывают, насколько важен каждый терм для этой темы.
- Столбцы матрицы V (правые сингулярные векторы) показывают веса документов для каждой темы. Они позволяют определить, насколько сильно каждый документ связан с каждой выявленной темой.
- Сингулярные числа в матрице Σ отражают важность каждой темы. Чем больше сингулярное число, тем более значима соответствующая тема в коллекции документов. Быстрое убывание сингулярных чисел указывает на то, что документы можно хорошо описать небольшим количеством основных тем.

2.2.5 Визуализация кластеризации




Рис. 7: Кластеризация слов и тем в пространстве первых двух компонент

Текста на графике обозначены красными точками, самые популярные тематические слова - синими. На графике хорошо видно, что слова разделились на две категории, каждая из которых растянулась вдоль осей x и y. Каждая из этих категорий представляет собой отдельную тему.

2.2.6 Анализ тем по словам

Попробуем определить темы по словам, которые наиболее выражены в каждой из категорий

Слова, растянутые по горизонтали:

- асфальт
- дорожный
- асфальтоукладчик
- горячий
- грунт

Из этих слов ярко прослеживается тематика дорожных работ. Аналогичным образом исследуем слова по вертикали

слова, растянутые по вертикали:

- жир
- белок
- включать
- добавка
- восполнять

Легко можно проследить тематику рациона и питания

2.2.7 Облака слов

На основе первых двух сингулярных векторов были выделены две основные темы в текстах:




Рис. 8: Облако слов для первой темы




Рис. 9: Облако слов для второй темы

2.2.8 Промежуточные выводы по LSA

Анализ текстов методом LSA показал:

- Четко выделяются две основные темы: дорожные работы и рацион
- Термины внутри каждой темы имеют сильные семантические связи
- Метод успешно справляется с синонимами и различными формами слов благодаря лемматизации

3 ВЫВОДЫ

3.1 По сжатию изображений

1. Интересным наблюдением стало то, что даже при $k=50$ (что составляет менее 15% от исходного размера) сохраняются все основные черты изображения.
2. Анализ сингулярных чисел показал, что после определенного момента вклад каждого следующего числа становится пренебрежимо малым, что позволяет эффективно определить оптимальное значение k .

3. Мы заметили, что при $k=200$ достигается оптимальный баланс между качеством и степенью сжатия для нашего конкретного изображения, что подтверждает эффективность SVD как метода сжатия с потерями.

3.2 По Latent Semantic Analysis

1. При анализе сингулярных чисел мы обнаружили, что для наших текстов достаточно всего двух- трех компонент для описания основной семантической структуры, что говорит о тематической сфокусированности текстов.
2. Визуализация в виде облака слов оказалась особенно полезной для понимания тематической структуры - она наглядно показала, как LSA группирует семантически связанные термины, даже если они не встречаются вместе в одном документе.

В целом, практическая работа с SVD показала, что этот метод действительно универсален и эффективен как для обработки изображений, так и для анализа текстов. Особенно впечатляет его способность находить скрытые структуры в данных, будь то визуальные паттерны или семантические связи.